

Sprawozdanie – Laboratorium 2

Metoda najmniejszych kwadratów

18.03.2026

Hubert Kukła, Maksymilian Siemek

1. Cel ćwiczenia

Celem ćwiczenia było wykorzystanie metody najmniejszych kwadratów do przewidywania roku wydania utworu na podstawie cech numerycznych. W zadaniu należało przygotować dane, wyznaczyć model liniowy, sprawdzić wpływ normalizacji na obliczenia oraz ocenić jakość predykcji na zbiorze testowym.

2. Opis danych

Wykorzystany został zbiór *YearPredictionMSD*, który zawiera 515 345 przykładów. Pierwsza kolumna oznacza rok wydania utworu, a pozostałe 90 kolumn to cechy opisujące utwór.

Zgodnie z poleceniem dane zostały podzielone na:

- zbiór treningowy: pierwsze 463 715 przykładów,
- zbiór testowy: pozostałe 51 630 przykładów.


W dalszej części oznaczono:

- y – wektor rzeczywistych lat wydania,
- X – macierz cech,
- w – wektor wag modelu.

Do macierzy cech została dodana kolumna jedynek, aby model uwzględniał wyraz wolny.


3. Wstępna analiza danych

Na początku wykonano histogram lat wydania utworów dla całego zbioru danych.



Rysunek 1: Histogram lat wydania utworów.

Następnie wykonano wykres liniowy na podstawie posortowanych wartości roku wydania.



Rysunek 2: Wykres posortowanych lat wydania.

Na podstawie wykresów można zauważyć, że dane obejmują szeroki zakres lat, ale większość utworów pochodzi z nowszych okresów.

4. Postać modelu

Zadanie sprowadza się do znalezienia takiego wektora wag w , aby model liniowy jak najlepiej przybliżał zależność między cechami a rokiem wydania utworu.

Predykcja modelu ma postać:

$$\hat{y} = Xw.$$

Wektor wag został wyznaczony metodą najmniejszych kwadratów z równań normalnych:

$$X^T X w = X^T y.$$

Stąd:

$$w = (X^T X)^{-1} X^T y.$$

5. Wyznaczenie współczynników modelu

Po zbudowaniu macierzy projektującej wyznaczono współczynniki modelu dla danych nieznormalizowanych. Otrzymano 91 współczynników, czyli wyraz wolny oraz 90 wag odpowiadających cechom wejściowym.

Wyraz wolny modelu wyniósł:

$$w_0 = 1951.1221815924844.$$

Przykładowe pierwsze współczynniki miały wartości:

$$w_1 = 0.87343914,$$

$$w_2 = -0.05581652,$$

$$w_3 = -0.04345260,$$

$$w_4 = 0.00351252.$$

W dalszej części rozwiązanie porównano również z podejściem wykorzystującym SVD, aby sprawdzić zgodność wyników.

6. Wpływ normalizacji

Następnie wykonano normalizację danych metodą min-max. W tym celu dla każdej cechy wyznaczono wartości minimalne i maksymalne na zbiorze treningowym, a potem użyto ich do przeskalowania zarówno zbioru treningowego, jak i testowego.

Normalizacja nie zmienia samej idei modelu, ale może poprawić warunki numeryczne obliczeń.

Aby to sprawdzić, policzono współczynnik uwarunkowania macierzy $X^T X$ przed i po normalizacji.

Wariant	Współczynnik uwarunkowania
Dane nieznormalizowane	3.87×10^9
Dane znormalizowane	2.15×10^6

Widać, że po normalizacji współczynnik uwarunkowania znacznie się zmniejszył. Oznacza to, że obliczenia stały się bardziej stabilne numerycznie, a wyznaczone współczynniki są mniej wrażliwe na błędy zaokrągleń.

7. Ocena jakości modelu

Jako miarę jakości modelu przyjęto średni błąd bezwzględny:

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|.$$

Obliczono wartość MAE dla danych nieznormalizowanych oraz znormalizowanych.

Wariant modelu	MAE
Dane nieznormalizowane	6.80 lat
Dane znormalizowane	6.80 lat

W obu przypadkach uzyskano praktycznie taki sam wynik. Jest to sensowne, ponieważ normalizacja w tym przypadku poprawia głównie stabilność obliczeń, ale nie musi wyraźnie zmieniać jakości samej predykcji.


8. Uczenie przyrostowe

W ostatniej części zadania wykonano wersję przyrostową. Dane treningowe były dzielone na kolejne partie, a po każdej z nich aktualizowano macierze potrzebne do wyznaczenia rozwiązania. Następnie po każdej paczce liczone błędy MAE na zbiorze testowym.

Otrzymano następujące wyniki:

Numer paczki	MAE
Paczka 1	6.8460
Paczka 2	6.8064
Paczka 3	6.7997
Paczka 4	6.8010
Paczka 5	6.8004


Na początku błąd był trochę większy, ale wraz z dodawaniem kolejnych partii danych szybko się ustabilizował i zbliżył do wyniku uzyskanego dla pełnego zbioru treningowego.




Rysunek 3: Zmiana wartości MAE dla kolejnych paczek danych.

9. Dodatkowe wykresy

Dla lepszej oceny działania modelu można też przedstawić porównanie wartości rzeczywistych i przewidywanych oraz histogram błędów.



Rysunek 4: Porównanie wartości rzeczywistych i przewidywanych.



Rysunek 5: Histogram błędów predykcji.

10. Wnioski

Na podstawie wykonanych obliczeń można stwierdzić, że metoda najmniejszych kwadratów pozwala w sensowny sposób przewidywać rok wydania utworu na podstawie cech numerycznych. Uzyskany średni błąd bezwzględny na poziomie około 6.80 lat oznacza, że model przeciętnie mylił się o około 7 lat, co można uznać za całkiem dobry wynik dla tego typu danych.

Na podstawie histogramu i wykresu posortowanych lat można zauważyć, że dane nie są rozłożone równomiernie. Większość utworów pochodzi z nowszych lat, co może wpływać na działanie modelu i sprawiać, że dla niektórych okresów przewidywanie jest łatwiejsze niż dla innych.

Porównanie wyników dla danych nieznormalizowanych i znormalizowanych pokazało, że normalizacja nie wpłynęła zauważalnie na wartość błędu MAE. Miała jednak bardzo duży wpływ na współczynnik uwarunkowania macierzy, czyli na stabilność numeryczną obliczeń. Oznacza to, że normalizacja była korzystna głównie z obliczeniowego punktu widzenia.

W części przyrostowej było widać, że wraz z dodawaniem kolejnych paczek danych wynik szybko stabilizował się w pobliżu wartości końcowej. Pokazuje to, że już dla części danych można uzyskać rezultat zbliżony do tego, który daje model uczony na pełnym zbiorze treningowym.

Podsumowując, model liniowy okazał się prostym, ale skutecznym narzędziem do rozwiązania tego zadania. Mimo że nie daje idealnych przewidywań, pozwala uchwycić ogólną zależność między cechami utworu a rokiem jego wydania.

11. Najważniejsze wzory

$$X_{\text{train}} = [\mathbf{1} \mid X]$$

$$w = (X^T X)^{-1} X^T y$$

$$\hat{y} = X_{\text{test}} w$$

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$