

MOwNiT – Laboratorium 6

Kwadratury numeryczne - analiza porównawcza

Data: 15.04.2026

Autorzy: Hubert Kukła, Maksymilian Siemek

1. Cel ćwiczenia

Celem laboratorium było zbadanie i porównanie efektywności różnych algorytmów całkowania numerycznego. Zadanie polegało na obliczeniu wartości całki oznaczonej:

$$I = \int_0^1 \frac{4}{1+x^2} dx = [4 \arctan(x)]_0^1 = \pi$$


Eksperyment pozwolił na analizę rzędu zbieżności metod deterministycznych (Newtona-Cotesa, Gaussa), metod adaptacyjnych oraz metody stochastycznej (Monte Carlo).

2. Zadanie 1. Klasyczne kwadratury Newtona-Cotesa

W zadaniu zaimplementowano złożone kwadratury: punktu środkowego (prostokątów), trapezów oraz Simpsona. Analizę przeprowadzono dla liczby podprzedziałów $n = 2^m$.

m	h	Błąd (Środkowy)	Błąd (Trapezy)	Błąd (Simpson)
1	0.500	6.608e-03	1.324e-02	2.629e-03
2	0.250	1.658e-03	3.316e-03	7.648e-06
4	0.062	1.036e-04	2.072e-04	7.528e-10
8	0.004	4.048e-07	8.095e-07	0.000e+00
16	1.5e-05	6.176e-12	1.235e-11	1.414e-16

Tabela 1: Wybrane błędy względne dla podstawowych metod całkowania.




Rysunek 1: Błąd względny dla kwadratur Newtona-Cotesa. Wyraźnie widoczna różnica w nachyleniu krzywych odpowiadająca rzędom zbieżności.

2.1. Wnioski do zadania 1

1. Rząd zbieżności: Metoda Simpsona wykazuje znacznie wyższy rząd zbieżności ($O(h^4)$) niż metody trapezów i punktu środkowego ($O(h^2)$). Dzięki temu osiąga ona precyzję rzędu 10^{-15} już przy niewielkiej liczbie kroków ($m = 8$), podczas gdy pozostałe metody wymagają tysięcy podziałów.
2. Przewaga punktu środkowego: Zgodnie z teorią, błąd metody punktu środkowego jest w przybliżeniu dwukrotnie mniejszy niż błąd metody trapezów dla tego samego kroku h . Wynika to z postaci reszty, gdzie stała dla punktu środkowego wynosi $\frac{1}{24}$, a dla trapezów $\frac{1}{12}$.
3. Nasycenie błędu: Przy bardzo dużych m (np. $m = 16$) błąd metody Simpsona przestaje spadać, co świadczy o osiągnięciu granicy precyzji zmiennoprzecinkowej double precision.

3. Zadanie 2. Kwadratura Gaussa-Legendre'a

Kwadratura Gaussa-Legendre'a wykorzystuje optymalnie dobrane węzły (zera wielomianów Legendre'a) oraz wagi. W odróżnieniu od metod Newtona-Cotesa, nie wymaga ona równomiernego rozkładu punktów.




Rysunek 2: Wykres błędów względnych dla metody Gaussa-Legendre'a.

3.1. Wnioski do zadania 2

1. Ekstremalna wydajność: Kwadratura Gaussa pozwala na uzyskanie wyników bliskich precyzji maszynowej przy zaledwie kilkunastu ewaluacjach funkcji. Jest to najskuteczniejsza metoda dla funkcji gładkich (klasy C^∞), takich jak analizowana w ćwiczeniu.
2. Optymalizacja węzłów: Dzięki temu, że węzły nie są narzucone odgórnie (jak w trapezach), metoda Gaussa-Legendre'a o n punktach całkuje dokładnie wielomiany stopnia aż do $2n - 1$.

4. Zadanie 3. Metody adaptacyjne

Zbadano adaptacyjną metodę trapezów oraz algorytm Gaussa-Kronroda. Metody te dynamicznie zagęszczają siatkę w obszarach, gdzie oszacowany błąd lokalny przekracza zadaną tolerancję.




Rysunek 3: Porównanie metod adaptacyjnych z metodami o stałym kroku. Metoda Gaussa-Kronroda (GK) dominuje pod względem precyzji przy małej liczbie punktów.

4.1. Wnioski do zadania 3

1. Inteligencja algorytmu: Metoda Gaussa-Kronroda jest najskuteczniejszą metodą. Problem pojawia się przy adaptacyjnych trapezach; prawdopodobnie wynika z tego, że funkcja jest bardzo gładka.
2. Gauss-Kronrod vs Trapezy: Adaptacyjna metoda trapezów wypada oczywiście gorzej od Gaussa-Kronroda, ponieważ bazuje na rzędzie $O(h^2)$. Gauss-Kronrod (podstawa funkcji quad w Pythonie) łączy zalety wysokiego rzędu Gaussa z możliwością taniego szacowania błędu.

5. Zadanie 4. Metoda Monte Carlo

Ostatnim etapem była implementacja metody stochastycznej, polegającej na losowaniu punktów z przedziału $[0, 1]$ i wyznaczaniu średniej wartości funkcji.



Rysunek 4: Błąd metody Monte Carlo w zależności od liczby próbek n . Charakterystyczne „poszarpanie” wykresu wynika z losowości procesu.

5.1. Wnioski do zadania 4

1. Powolna zbieżność: Metoda Monte Carlo wykazuje bardzo słabą zbieżność $O(n^{\{-\frac{1}{2}\}})$. Aby poprawić wynik o jedno miejsce po przecinku, należy zwiększyć liczbę próbek aż 100-krotnie.
2. Zastosowanie: Dla całek jednowymiarowych metoda ta jest nieefektywna. Jej kluczową zaletą, której nie widać w tym ćwiczeniu, jest niezależność błędu od wymiarowości problemu, co czyni ją niezastąpioną w całkach wielowymiarowych (tzw. klątwa wymiarowości).

6. Empiryczny rząd zbieżności

Empiryczny rząd zbieżności p wyznaczono przez dopasowanie prostej do punktów w skali logarytmicznej metodą najmniejszych kwadratów. Jeżeli błąd metody zachowuje się asymptotycznie jak

$$\varepsilon \approx C \cdot h^p,$$

to po obustronnym zlogarytmowaniu otrzymujemy zależność liniową:

$$\log \varepsilon \approx \log C + p \log h.$$

Współczynnik kierunkowy tej prostej odpowiada empirycznemu rzędowi zbieżności p .

Dla metod deterministycznych, czyli metody punktu środkowego, trapezów oraz Simpsona, jako zmienną niezależną przyjęto krok

$$h = \frac{1}{n}.$$

Dla metody Monte Carlo zamiast kroku h użyto liczby punktów próbkowania n , ponieważ dla tej metody błąd zależy od liczby losowanych próbek.

Metoda	Empiryczny rząd zbieżności p	Oczekiwany rząd teoretyczny
Punkt środkowy	1.884	2
Trapezy	1.899	2
Simpson	6.022	4
Monte Carlo	0.436	0.5

Tabela 1: Porównanie empirycznego i teoretycznego rzędu zbieżności dla badanych metod.

Dla metody punktu środkowego oraz metody trapezów otrzymane empiryczne rzędy zbieżności są bliskie wartości teoretycznej $p = 2$. Oznacza to, że wyniki numeryczne dobrze potwierdzają przewidywania teoretyczne.

Dla metody Monte Carlo otrzymano empiryczny rząd zbieżności równy około 0.436, co jest wynikiem zbliżonym do wartości teoretycznej 0.5. Wartość 0.5 wynika z faktu, że błąd metody Monte Carlo maleje średnio jak

$$\varepsilon(n) = O\left(\frac{1}{\sqrt{n}}\right) = O(n^{-\frac{1}{2}}).$$

Dla metody Simpsona otrzymany empiryczny rząd zbieżności 6.022 jest większy od teoretycznego rzędu 4. Wynika to najprawdopodobniej ze specyfiki badanej funkcji oraz z faktu, że dla bardzo małych błędów wyniki zbliżają się do granicy precyzji maszynowej. Dlatego wynik ten należy traktować jako efekt eksperymentalny, a nie jako zmianę ogólnego rzędu metody Simpsona.

7. Wnioski końcowe

1. Wybór metody: Do obliczeń na funkcjach gładkich (jak w naszym przypadku) bezsprzecznie najlepsza jest kwadratura Gaussa-Legendre'a lub Gaussa-Kronroda.
2. Stabilność numeryczna: Wszystkie metody deterministyczne w pewnym momencie uderzają w „ścianę” precyzji `float64`, gdzie dalsze zagęszczanie siatki nie poprawia wyniku, a może go pogorszyć przez kumulację błędów zaokrągleń.
3. Efektywność obliczeniowa: Metoda Simpsona jest złotym środkiem wśród metod o stałym kroku – jest prosta w implementacji i nieporównywalnie szybsza od trapezów.