

MOwNiT - Laboratorium 11

Optymalizacja

Data: 20.05.2026

Autor: Hubert Kukła

1. Cel ćwiczenia

Celem laboratorium było przećwiczenie metod optymalizacji numerycznej na trzech przykładach: preconditioningu w funkcji kwadratowej, minimalizacji energii wiszącego łańcucha oraz regresji liniowej rozwiązywanej metodą gradientu prostego. W każdym zadaniu zapisano osobno podpunkty z treści, a wyniki uzupełniono wykresami.

2. Zadanie 1. Preconditioning

Dana była funkcja

$$f(x, y) = \frac{1}{2}x^2 + \frac{9}{2}y^2$$

. Jej gradient i hesjan są równe

$$\nabla f(x, y) = \begin{pmatrix} x \\ 9y \end{pmatrix}$$

oraz

$$H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}$$

.

2.1. Podpunkt (a). Gradient prosty z optymalnym krokiem

Dla funkcji kwadratowej zastosowano krok dokładny w kierunku antygradientu:

$$\alpha_k = \frac{\nabla f(z_k)^T \nabla f(z_k)}{\nabla f(z_k)^T H \nabla f(z_k)}$$

. Punkt startowy wynosił $z_0 = \begin{pmatrix} 9 \\ 1 \end{pmatrix}$. Algorytm zbiega do minimum $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$, ale bez zmiany zmiennych wykonuje charakterystyczne zygzakowanie między wąskimi poziomiami. Dla przykładu po 11 iteracjach otrzymano w przybliżeniu $x = 0.7731$, $y = -0.0859$, $f = 0.332041$.




Figure 1: Kontury funkcji f i iteracje gradientu prostego z punktu $(9, 1)$.

2.2. Podpunkt (b). Współczynnik uwarunkowania

Wartości własne macierzy H są równe 1 oraz 9, dlatego

$$\kappa_2(H) = \frac{\lambda_{\max}}{\lambda_{\min}} = 9$$

. Duża różnica krzywizn w kierunkach osi x i y tłumaczy powolne zbieranie klasycznego gradientu prostego.

2.3. Podpunkt (c). Macierz L

Wystarczy wziąć diagonalny pierwiastek Cholesky'ego:

$$L = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}$$

oraz

$$LL^T = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix} = H$$

2.4. Podpunkt (d). Minimalizacja po zmianie zmiennych

Po podstawieniu

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = L \begin{pmatrix} x \\ y \end{pmatrix}$$

otrzymujemy $x = x'$ oraz $y = \frac{y'}{3}$, więc

$$g(x', y') = f\left(x', \frac{y'}{3}\right) = \frac{1}{2}(x')^2 + \frac{1}{2}(y')^2$$

. Hessian funkcji g jest macierzą jednostkową, a punkt startowy przechodzi w $u_0 = \begin{pmatrix} 9 \\ 3 \end{pmatrix}$. Metoda gradientu prostego z dokładnym krokiem ma wtedy $\alpha = 1$ i dochodzi do $u_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ w jednej iteracji. Ze wzoru $z = L^{-T}u$ dostajemy minimum funkcji wyjściowej: $(x, y) = (0, 0)$.




Figure 2: Po zmianie zmiennych poziomice są okręgami, więc gradient prosty trafia w minimum w jednej iteracji.

2.5. Wnioski do zadania 1

1. Współczynnik uwarunkowania równy 9 powoduje widoczne zygzakowanie metody gradientu prostego.
2. Preconditioning przez L zamienia elipsy poziomice w okręgi.
3. Dla funkcji g problem jest idealnie uwarunkowany i metoda z dokładnym krokiem kończy się po jednej iteracji.

3. Zadanie 2. Wiszący łańcuch

Łańcuch opisano przez $n + 1 = 41$ mas punktowych. Końce były ustalone w punktach $(0, 0)$ i $(3, 1)$, natomiast zmiennymi optymalizacji były współrzędne punktów wewnętrznych. Energia całkowita składała się z energii sprężyn oraz energii grawitacyjnej:

$$V = \frac{1}{2}k \sum_{i=0}^{n-1} (d_i - L)^2 + mg \sum_{i=0}^n y_i$$

, gdzie

$$d_i = \sqrt{(x_i - x_{i+1})^2 + (y_i - y_{i+1})^2}$$

.

3.1. Gradient funkcji celu

Dla sprężyny między punktami i i $i + 1$ wkład do gradientu punktu i ma postać

$$k \frac{d_i - L}{d_i} \begin{pmatrix} x_i - x_{i+1} \\ y_i - y_{i+1} \end{pmatrix}$$

, a wkład do punktu $i + 1$ ma przeciwny znak. Do każdej pochodnej po y_j dochodzi dodatkowo składnik $mc \cdot g$. W implementacji najpierw zsumowano wkłady wszystkich sprężyn, a następnie pozostawiono tylko współrzędne punktów wewnętrznych.

3.2. Podpunkt (a). Stały współczynnik uczenia

Dla stałego kroku użyto $\alpha = 0.002$. Metoda dochodzi do tej samej energii końcowej, ale wymaga wielu iteracji, ponieważ krok musi być wystarczająco mały, aby nie zdestabilizować sprężyn.

3.3. Podpunkt (b). Współczynnik malejący wykładniczo

Użyto $\alpha_t = 0.003 \cdot 0.98^{\lfloor \frac{t}{1000} \rfloor}$. Większy krok początkowy przyspiesza zejście z początkowej konfiguracji, a powolne zmniejszanie kroku stabilizuje końcowe iteracje.

3.4. Podpunkt (c). Przeszukiwanie liniowe

Zastosowano backtracking z warunkiem Armijo. Ta wersja sama dobiera krok i w tym eksperymencie wymagała najmniejszej liczby iteracji.

Metoda	Iteracje	Energia	Norma gradientu	Czas s	min y
stały krok alpha=0.002	17330	-51.458276	9.996e-06	1.313	-4.059
alpha wykładniczo malejące	13002	-51.458276	9.996e-06	1.020	-4.059
przeszukiwanie liniowe	4185	-51.458276	9.710e-06	0.980	-4.059




Figure 3: Końcowe położenie mas łańcucha dla trzech wersji gradientu prostego.




Figure 4: Zmiana energii potencjalnej w kolejnych iteracjach.

3.5. Wnioski do zadania 2

1. Wszystkie trzy warianty prowadzą do praktycznie tej samej konfiguracji końcowej i energii około -51.4583 .
2. Najniższy punkt łańcucha ma współrzędną y około -4.059 , co jest zgodne z intuicją: łańcuch opada pod wpływem grawitacji.
3. Przeszukiwanie liniowe jest najwygodniejsze, bo nie wymaga ręcznego strojenia stałego kroku i w tym uruchomieniu wykonało najmniej iteracji.

4. Zadanie 3. Predykcja roku wydania utworu

Problem regresji zapisano jako minimalizację

$$F(w) = \frac{1}{2m} \|Aw - y\|_2^2$$

. Gradient ma postać

$$\nabla F(w) = \frac{1}{m} A^T(Aw - y)$$

. Stałą uczącą wyznaczono z wartości własnych macierzy $A^T \frac{A}{m}$:

$$\alpha = \frac{2}{\lambda_{\min} + \lambda_{\max}}$$

Wykorzystano plik YearPredictionMSD.txt z laboratorium 2. Zbiór ma 515345 wierszy i 91 kolumn: pierwsza kolumna to rok wydania, a pozostałe 90 kolumn to cechy. Zgodnie z opisem danych pierwsze 463715 przykładów przyjęto jako zbiór treningowy, a pozostałe 51630 jako zbiór testowy. Po standaryzacji cech i dodaniu wyrazu wolnego macierz treningowa miała rozmiar 463715 x 91.

Dla pełnego zbioru wygodnie jest utworzyć macierz Grama $H = A^T \frac{A}{m}$ oraz wektor $b = A^T \frac{y}{m}$. Wtedy gradient można liczyć jako $Hw - b$, co jest równoważne klasycznemu gradientowi dla tej funkcji kwadratowej, ale po jednorazowym przygotowaniu macierzy nie wymaga mnożenia przez wszystkie

wiersze danych w każdej iteracji. W tym uruchomieniu otrzymano $\alpha = 0.19210274$, $\lambda_{\min} = 5.88753917 \cdot 10^{-2}$, $\lambda_{\max} = 1.03522200 \cdot 10^1$ oraz $\kappa(H) \approx 175.83$.

4.1. Porównanie dokładności i czasu

Metoda	RMSE test	MAE test	Czas s	Iteracje
najmniejsze kwadraty	9.5102	6.8005	0.4199	1
gradient prosty	9.5102	6.8005	0.4452	1413




Figure 5: Zbieżność gradientu prostego: wartość funkcji celu oraz norma gradientu z zaznaczoną tolerancją stopu.




Figure 6: Porównanie wartości rzeczywistych i predykcji gradientu prostego.

4.2. Złożoność obliczeniowa

Metoda	Koszt teoretyczny	Komentarz
Najmniejsze kwadraty	$O(md^2 + d^3)$	Koszt obejmuje utworzenie równań normalnych i rozwiązanie układu wymiaru d .
Gradient prosty	$O(md^2 + d^3 + Td^2)$	W użytej wersji najpierw tworzone H i wyznaczano wartości własne, a potem każda iteracja kosztowała $O(d^2)$. Bez macierzy Grama pojedyncza iteracja miałaby koszt $O(md)$.

4.3. Wnioski do zadania 3

1. Gradient prosty uzyskał praktycznie taki sam błąd testowy jak metoda najmniejszych kwadratów.
2. Błąd MAE około 6.8005 roku jest zgodny z wynikiem z laboratorium 2 dla metody najmniejszych kwadratów.
3. Gradient prosty zatrzymał się po 1413 iteracjach, gdy norma gradientu spadła poniżej 10^{-7} .
4. Wykres wartości funkcji celu szybko dochodzi do poziomu minimalnego błędu regresji, dlatego po kilkudziesięciu iteracjach wygląda prawie płasko.
5. Czytelniejszą miarą zatrzymania algorytmu jest norma gradientu. Jej prawie liniowy spadek na wykresie logarytmicznym jest oczekiwany dla funkcji kwadratowej i stałego optymalnego kroku: odpowiada geometrycznej, czyli wykładniczej, zbieżności błędu optymalizacji.
6. Przy $d = 91$ czas przygotowania macierzy H dominuje nad samym rozwiązywaniem małego układu i nad iteracjami gradientu.
7. Dobór kroku z wartości własnych daje stabilną zbieżność bez ręcznego strojenia parametru uczenia.

5. Wnioski końcowe

1. Preconditioning może diametralnie poprawić zbieżność gradientu prostego, co najlepiej widać w zadaniu 1.
2. W problemach fizycznych, takich jak wiszący łańcuch, najważniejsze jest poprawne wyprowadzenie gradientu i traktowanie punktów brzegowych jako stałych.
3. Stały krok jest prosty, ale wymaga strojenia; przeszukiwanie liniowe zwykle lepiej adaptuje się do lokalnej geometrii funkcji celu.
4. W regresji liniowej gradient prosty i najmniejsze kwadraty rozwiązują ten sam problem optymalizacyjny, ale różnią się kosztem: metoda bezpośrednia jest szybka dla małego d , a gradient prosty skaluje się lepiej iteracyjnie dla dużych zbiorów.
5. Wykresy konturowe, wykresy energii i wykresy zbieżności są dobrym uzupełnieniem samych tabel, ponieważ pokazują mechanikę działania algorytmów.